

store2hdf5.m

一个自定义函数，用于后面主函数生成h5文件

<1>Input

(1)filename:

- 1 | 文件路径和文件名，例如./xxx.h5

(2)data:

- 1 | 归一化的W,H,C,N矩阵（W代表水平方向像素个数，H代表竖直方向像素个数，C代表通道数，N代表图像的张数）

这里补充一下两种格式的图像数据



NCHW格式同一个通道内的像素存储在一起，RRRRGGGGBBBB，[batch_size,channel,height,width]

NHWC则是以图像空间位置为顺序，同一个位置的三通道数据存储在一起，RGBRGBRGBRGB
[batch_size height width channel]

(3)create:

- 1 | 确定创建方式是新建还是追加（默认为值为1，新建模式）
- 2 | 0:追加模式
- 3 | 1:新建模式

(4)startloc:

- 1 | 数据起始写入位置指针：默认情况下
- 2 | 如果create=0,则startloc.data=[1 1 1 K+1],startloc.lab = [1 K+1]; 其中K是当前存入HDF文件中的样本数
- 3 | 如果create=1,则startloc.data=[1 1 1 1],startloc.lab=[1 1];

(5)chunksz:

- 1 | 只在新建模式(create=1)下有效，指定每一块中样本数量的多少，块越大，读写操作越快

<2>output

- 1 | curr_dat_sz: 返回当前数据集的大小

<3>功能:

- 1 创建一个h5文件并写入内容，并返回h5文件中当前写入的数据集大小

<4>实现功能的主要函数

h5create

- 1 <1>Input:h5create(filename,ds,sz,Name,value,.....)
- 2 (1)filename:h5文件名（带路径）
- 3 (2)ds:数据集的名字（因为h5文件有组合数据，所以这里用字符串向量来区分组合数据，例如'/g1/g2/myDataset'就代表三组和一个数据集，三个组分别是/,g1,g2,数据集是myDataset）
- 4 (3)sz:数据集大小，行向量，例如[100 200 300]就是100x200x300的数据集，如果要指定无限维度,使用Inf指定(要使用Inf，必须设置ChunkSize参数)
- 5 (4)Name,value:matlab中的通过键值对指定参数赋值，常见的如下
- 6 'Datatype':'double'(默认)'single''uint64''int64''uint32''int32''uint16''int16''uint8''int8''string'
- 7 'ChunkSize':行向量指定，行向量维度必须和sz一致
- 8
- 9 <2>Output:无输出
- 10
- 11 <3>功能：创建.h5类型文件

h5write

- 1 <1>Input:h5write(filename,ds,data,start,count)
- 2 (1)(2)前两个参数和h5create一模一样
- 3 (3)data:数值矩阵，要写入h5文件的数据，类型必须和创建数据集时候的一致。如果不指定 start 或 count，则数据必须为非稀疏的，并且必须与 HDF5 数据集大小相同。如果数据集中的一个是无限的，则要写入的数据的该维度可以是任何大小。
- 4 (4)start:数值向量，向量中的每一个元素指定对应维度的起始索引位置，未指定默认从1开始
- 5 (5)count:数值向量，向量中的每一个元素指定对应维度写入的数据的个数，默认是Inf向量
- 6
- 7 <2>Output:无输出
- 8
- 9 <3>功能：像h5文件中写入内容

h5info

- 1 <1>Input:info = h5info(filename)
- 2 filename:h5的文件名
- 3
- 4 <2>Output:一个信息结构体
- 5
- 6 <3>功能:返回整个 HDF5 文件的有关信息，包括其中包含的组、数据集和命名数据类型的有关信息

返回的信息结构体中有如下内容：

文件和组

字段	说明
Name	用来指定组或数据集名称的字符向量。如果您只指定 HDF5 文件名，该函数将返回根组的有关信息。
Groups	描述子组的结构体数组。
Datasets	描述数据集的结构体数组。
Datatypes	描述给定数据类型的结构体数组。
Links	描述用户定义的外部软链接和某些硬链接的结构体数组。
Attributes	描述组属性的结构体数组。

数据集

字段	说明
Name	指定数据集名称的字符向量。
Datatype	描述数据类型的结构体。
Dataspace	描述数据集大小的结构体。
ChunkSize	数据集分块大小的维度（如果已定义）。
FillValue	缺失数据的填充值（如果已定义）。
Filter	描述任何定义的筛选器（例如压缩）的结构体数组。
Attributes	描述数据集属性的结构体数组。

给定数据类型

字段	说明
Name	用来指定数据类型对象名称的字符向量。
Class	给定数据类型的 HDF5 类。
Type	用来进一步描述数据类型的字符向量或结构体。
Size	给定数据类型的大小（以字节为单位）。

create_h5_file.m

主要讲解几个预定义常量对整个程序的作用(在这里预定义常量就相当于输入参数)

savepath

- 1 | 这个量控制最后h5文件要存储的路径和名字


size_input(相当于patch_size)

- 1 | 这个量控制样本图像框的大小，这个大小必须小于等于实际读取到的源图像的大小，否则会运行出错，这个参数也可以影响最终h5文件的大小，如果小于实际大小，就意味着要切块


大于的情况

工作区		命令行窗口
名称 ▲	值	
batch_num	[]	
c	1	
channel	1	
chunksz	10	
count	0	
create_flag	1	
data	[]	
filepath1	20x1 struct	
filepath2	20x1 struct	
folder1	'F:\论文实验复...	
folder2	'F:\论文实验复...	
Format	'*.png'	
height	256	
i	20	
img_ch	1	
L	20	
L1	20	
L2	20	
order	[]	
ratio	1	
savepath	'F:\论文实验复...	
size_input	300	
stride	200	
totalct	0	
width	256	
x	[]	

等于的情况



小于的情况



stride

这个变量的中文意思是步长，然后相关代码出现在子图像制作的地方，但是我调整步长之后，并没有发现子图像有什么改变，然后最后制作出来的h5文件大小也没有改变，所以推测可能步长的大小影响子图像制作的速度吧，相关代码如下(纠正，步长决定采样频率，但是要搭配input_size才有效)

```
1 for x=1:stride:(height-size_input+1)
2     for y=1:stride:(width-size_input+1)
3         sub_img1(:,:,:)=i1(x:x+size_input-1,y:y+size_input-1,:);
4         sub_img2(:,:,:)=i2(x:x+size_input-1,y:y+size_input-1,:);
5         count=count+1;
6         data(:,:,1:1+img_ch-1,count)=sub_img1(:,:,:);
7         data(:,:,1+img_ch:1+2*img_ch-1,count)=sub_img2(:,:,:);
8
9         %这里有画图显示
10        figure(1)
11        A=data(:,:,1:1+img_ch-1,count);
12        B=data(:,:,1+img_ch:1+2*img_ch-1,count);
13        subplot(221),imshow(A);
14        subplot(222),imshow(B);
15        subplot(223),imshow(sub_img1);
16        subplot(224),imshow(sub_img2);
17    end
18 end
```

Format

- 1 这个参数是拿来读取文件的，支持通配符，例如要读取.png图像，就设置成 *.png


img_ch

- 1 这个是控制读取的图像类型，是灰度图还是RGB真彩色
- 2 =1:灰度图
- 3 =3:RGB
- 4 这里设置成1还是设置成3要看自己的源图像是什么类型的图像

ratio


- 1 这个参数控制放大比例，只能放大，即 $\text{ratio} \geq 1$ ，放大之后最后制作出来的h5文件会变大，成正比

两倍



注意这里图片显示不完和之前的input_size小于实际图片大小显示不完是两种机理，这里没显示完是因为窗口大小只能显示部分，实际上是存入了完整的放大图片，而前面显示不完，是因为只能读取部分

不放大



Medical_dataset.h5

2022/9/7 17:19

H5 文件

10,245 KB

输出curr_dat_sz

返回最后一次写入数据集的样本数

```
i =
```

```
10
```

时间已过 1.895662 秒。

```
i =
```

```
20
```

时间已过 3.547008 秒。

Creating dataset with 10 samples

最重要的几个参数

```
1 <1>chuncksz对应batch_size:即每一批多少块
2 <2>input_size对应patch_size: 即每一块多大
3 <3>图片的height和width 和stride以及input_size共同决定一张图片能制作多少块
4 num=int[(height-inputsize)/stride]*int[(width-input_size)/stride]
5 <4>如果再考虑了放大比例ratio之后
6 num=int[(height*ratio-inputsize)/stride]*int[(width*ratio-input_size)/stride]
7 例如256x256原图片, stride=64,ratio=4,input_size=256
8 则num=int[(256*4-256)/64]*int[(256*4-256)/64]=144块
```